

SUBIEKTYWNA OCENA QOE WIDEO NA PODSTAWIE REAKCJI NA DEGRADACJĘ JAKOŚCI W RÓŻNYCH GRUPACH WIEKOWYCH

SUBJECTIVE VIDEO QOE ASSESSMENT BASED ON REACTION ON QUALITY DEGRADATION IN DIFFERENT AGE GROUPS

Dominika Wanat¹; Dawid Juszka²

¹ AGH Akademia Górniczo-Hutnicza, Kraków,
dominika.wanat@agh.edu.pl

² AGH Akademia Górniczo-Hutnicza, Kraków,
dawid.juszka@agh.edu.pl

Streszczenie: W Rekomendacjach ITU-T Absolute Category Rating (ACR) jest prezentowana jako wiodąca metoda przeprowadzania testów subiektywnych wideo. Niestety, standardowa procedura eksperymentu nie bierze pod uwagę czynników zaburzających ocenę. Z tego powodu, zaproponowaliśmy nową procedurę testów subiektywnych opartą o reakcję użytkownika na niesatysfakcjonującą jakość wideo. Zaadaptowana metoda dopasowania funkcji psychometrycznych pozwoliła porównać postrzeganie jakości wideo w trzech grupach wiekowych.

Abstract: ITU-T Recommendations suggest Absolute Category Rating (ACR) as a leading method of conducting subjective video quality tests. Unfortunately, the standard experiment procedure does not consider factors that could skew the ratings. Consequently, we proposed a novel subjective test procedure based on the user's reaction to dissatisfactory quality. The adapted method of fitting psychometric functions allows the perception of video quality in three age groups to be compared.

Słowa kluczowe: QoE (Quality of Experience), testy subiektywne, metoda największej wiarygodności, funkcje psychometryczne, postrzeganie jakości

Keywords: QoE (Quality of Experience), subjective tests, Maximum Likelihood Estimation (MLE), psychometric functions, quality perceptions

1. WSTĘP

Konwencjonalne testy subiektywne sprawdzające jak ludzie postrzegają jakość wideo, przeprowadzane są zazwyczaj według wytycznych zawartych w rekomendacjach ITU-T oraz ITU-R. Sekwencje wideo mogą być oceniane z użyciem metryk niereferencyjnych, takich jak: Naturalness Image Quality Evaluator (NIQE), Video BLINDS (V-BLINDS) [7], Perception-based Image Quality Evaluator (PIQE) [9], Blind/Referenceless Image Spatial Quality Evaluator (BRISQUE) [2] czy metryk wykorzystujących sieci neuronowe, oraz referencyjnych, takich jak Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index (SSIM), Video Quality Metric (VQM) czy Video Multi-Method Assessment Fusion (VMAF) [5].

Jednak niektóre rekomendacje, takie jak ITU-T P.917 [3], zwracają także uwagę na szereg czynników, które mogą mieć dodatkowy wpływ zarówno na zachowanie uczestnika badań, jak i na udzieloną przez niego ocenę jakości wideo. Należą do nich:

- motywacje do obejrzenia danego wideo: zarówno wewnętrzna, jak i zewnętrzna,
- hipoteza testowa zaprezentowana użytkownikowi;
- realizm środowiska, w którym przeprowadzone są badania;
- przyjęte założenia oraz kontekst użycia.

Niniejsze czynniki mogą sprawiać, że użytkownicy będą mniej krytyczni (w przypadku braku motywacji, czy to zewnętrznej, czy wewnętrznej) lub będą one zaburzać oceny (w pozostałych przypadkach) [3].

Aby zniwelować ich wpływ, zaproponowaliśmy zupełnie nową procedurę eksperymentu subiektywnego. W tym celu odeszliśmy od klasycznego prezentowania krótkich, niemych sekwencji wideo oraz oceny ich jakości za pomocą pięciostopniowej skali ACR. W zamian pozwoliliśmy użytkownikom na wybór dowolnego filmu na platformie Netflix. Zupełnie nowym elementem w procedurze eksperymentu była możliwość reakcji na degradację jakości, kiedy stanie się ona dla użytkownika niesatysfakcjonująca. Pozwoliło to na obserwacje bardziej realistycznego zachowania użytkownika w obliczu degradacji jakości. Szczegółowa procedura eksperymentu jest opisana w Sekcji 2.1.

W rezultacie otrzymaliśmy dane dotyczące zachowania użytkowników, które wymagały nowego sposobu analizy danych. Zaadoptowaliśmy więc do naszych potrzeb metodę **dopasowania funkcji psychometrycznych**, znaną w psychologii, neurobiologii oraz naukach zajmujących się zachowaniem zwierząt i ludzi [4].

W wyniku dopasowania otrzymaliśmy funkcje obrazujące relację pomiędzy natężeniem bodźca oraz prawdopodobieństwem reakcji dla każdego użytkownika. Wykresy zostały dopasowane z użyciem pakietu R *Quickpsy* [6] za pomocą metody największej wiarygodności (ang. *Maximum Likelihood Estimation*, MLE). W przypadku naszego eksperymentu, za metrykę opisującą jakość wideo posłużyła nam odwrócona metryka VMAF (rVMAF) [5],

natomiast miarą reakcji na degradację jakości stało się prawdopodobieństwo naciśnięcia przycisku poprawiającego jakość. Szczegółowe informacje na temat modelu oraz dopasowania można znaleźć w Sekcji 2.2.

Zaproponowany eksperyment został przeprowadzony w laboratorium na grupie 34 osób. Otrzymane wykresy i ich parametry dostarczyły nam znacznie bardziej szczegółowych informacji o użytkowniku: jego konsekwencji (poprzez nachylenie funkcji – ang. *slope*) oraz punkcie, w którym użytkownik zaczyna zauważać różnicę w jakości (ang. *Point of Subjective Equality, PSE*) [1].

2. METODY

2.1 Procedura eksperymentu

W naszym nowym eksperymencie subiektywnym mogła wziąć udział każda osoba powyżej 18 roku życia nie będąca pracownikiem AGH (ograniczenie to wynikało z wymogów formalnych uczelni). Po zakończeniu eksperymentu otrzymywała ona wynagrodzenie w wysokości 200 PLN. Zgłoszenia odbywały się poprzez formularz online. Pierwszym etapem eksperymentu było sprawdzenie parametrów wzroku osoby chętnej do udziału w eksperymencie: wady wzroku oraz zaburzeń widzenia barw. W tym celu zostały użyte tablice Snellena oraz test Ishihary.

Następny etap obejmował dopełnienie formalności związanych z udziałem w eksperymencie. Jeśli uczestnik nie zadeklarował w formularzu jaki film chce obejrzeć podczas eksperymentu, eksperymentator odczytywał mu streszczenia trzech filmów: „The Highwayman” (thriller), „Faraway” (komedia romantyczna) oraz „The Old Guard” (film akcji/fantasy) i prosił o wybranie jednego z nich.

W końcu uczestnik był zapraszany do wygłuszonego pomieszczenia, gdzie znajdowały się dwie małe sofy, stolik RTV, na którym stał telewizor oraz przycisk pozwalający na reakcję i mały stolik boczny. Wygląd tego pomieszczenia został zaprezentowany na Rysunku 1.



Rysunek 1: Pomieszczenie eksperymentu. Po lewej stronie stołu z telewizorem widoczny jest przycisk pozwalający na reakcję na zmieniającą się jakość.


Uczestnicy byli zachęceni do swobodnego ustawienia stolika bocznego oraz drugiej sofy. Uczestnik oglądał instrukcję wideo wyjaśniającą przebieg eksperymentu, w szczególności, że jakość wideo może zmieniać się w czasie oglądania filmu. Kiedy jakość filmu stanie się nieakceptowalna dla uczestnika, może on przywrócić ją do najwyższej możliwej używając przycisku znajdującego się przy telewizorze. Przycisk mógł być używany w każdym momencie, zmiana jego lokalizacji i pozycji była jednak niedozwolona. Końcowy etap konfiguracji obejmował odpowiadanie na dodatkowe pytania uczestnika oraz preferencje dotyczące języka lektora oraz napisów. Po naciśnięciu przycisku „Start”, następowała konfiguracja języka oraz napisów odtwarzacza wybranego filmu przez eksperymentatora i eksperymentator opuszczał pomieszczenie.

Tylko eksperymentator posiadał wiedzę, że zadaniem wtyczki do odtwarzacza serwisu Netflix w czasie trwania całego filmu była monotoniczna degradacja jakości do najgorszej dostępnej dla tego filmu (opisanej metryką VMAF). Każde naciśnięcie przycisku ponownie przywracało najlepszą dostępną jakość i rozpoczynało stopniową jej degradację.

Uczestnik był obserwowany w trakcie trwania całego filmu, aby w razie wystąpienia poważnych problemów technicznych lub zdrowotnych uczestnika miał możliwość szybkiej reakcji. Na zakończenie uczestnik wypełniał kwestionariusz dotyczący jego odczuć i wrażeń z eksperymentu oraz doświadczenia z platformami wideo.

2.2 Dopasowanie funkcji psychometrycznej

Wyniki uzyskane od każdego uczestnika eksperymentu zostały dopasowane funkcją psychometryczną. Opisuje ona prawdopodobieństwo reakcji uczestnika od jakości wyświetlanego wideo definiowaną poprzez odwróconą metrykę VMAF (rVMAF), wyrażoną wzorem 1. Przykładowe dopasowanie funkcji psychometrycznej do danych uzyskanych w eksperymencie widoczne jest na Rysunku 2.



Rysunek 2: Przykładowe funkcje psychometryczne uczestników eksperymentu.

$$rVMAF = 100 - VMAF \quad (1)$$

Z tego powodu używając metody największej wiarygodności możemy opisać tę relację:

$$f(\mathbf{k}; \boldsymbol{\theta}) = \prod_{i=1}^M \binom{n_i}{k_i} \psi(x_i; \boldsymbol{\theta})^{k_i} (1 - \psi(x_i; \boldsymbol{\theta}))^{n_i - k_i} \quad (2)$$

gdzie:

- f – funkcja gęstości prawdopodobieństwa;
- M – liczba prezentowanych użytkownikowi różnych poziomów rVMAF;
- x_i – i -ta sekwencja wideo o danej jakości opisanej przez rVMAF;
- n_i – liczba sekwencji wideo, w których prezentowany jest dany rVMAF (x_i);
- $k = (k_1, k_2, \dots, k_M)$ wektor naciśnięć przycisku przy danej jakości;
- $\psi(x_i; \theta)$ – prawdopodobieństwo naciśnięcia przycisku kiedy i -ty rVMAF jest obserwowany – funkcja psychometryczna o następującej formie:

$$\psi(x; \theta) = \psi(x; \alpha, \beta, \gamma, \lambda) = \gamma + (1 - \gamma - \lambda)F(x; \alpha, \beta) \quad (3)$$

gdzie:

- θ – wektor definiujący rodzinę funkcji parametrycznych gęstości dla funkcji masy prawdopodobieństwa modelu;
- α, β – parametry: pozycja i skala;
- γ, λ – lewostronna i prawostronna asymptota ψ ;
- F – funkcja (rozkład) o sygmoidalnym kształcie, lewostronnej asymptocie w 0 oraz prawostronnej asymptocie w 1. Porównując grupy wiekowe do modelowania używamy rozkładu Weibulla, który zdefiniowany jest następująco:

$$F_W(x; \alpha, \beta) = 1 - e^{-\left(\frac{x}{\alpha}\right)^\beta} \quad (4)$$


Rozkład ten ma dwa parametry: α oraz β . Parametr α zwiemy progiem psychofizycznym i określa on, jaki poziom jakości musi być zaprezentowany, aby otrzymać konkretne prawdopodobieństwo naciśnięcia przycisku. Parametr β nazywany jest nachyleniem funkcji i opisuje niepewność (niekonsekwencję) uczestnika eksperymentu. [4].

Estymacja parametru θ jest dokonywana poprzez metodę największej wiarygodności. Szukamy takiego parametru θ , który maksymalizuje prawdopodobieństwo L definiowane jako $L(\theta) = f(\mathbf{k}; \theta)$, co jest jednoznaczne z maksymalizacją $\log L(\theta)$. Transformując równanie 2 otrzymujemy:

$$\log L(\theta) = \sum_{i=1}^M \left(\log \binom{n_i}{k_i} + k_i \log \psi(x_i; \theta) + (n_i - k_i) \log(1 - \psi(x_i; \theta)) \right) \quad (5)$$

3. WYNIKI


W eksperymencie opisanym w Sekcji 2.1 wzięło udział 34 uczestników: 11 mężczyzn, 22 kobiety oraz 1 osoba bez deklaracji płci. Uczestników eksperymentu podzielono na trzy grupy wiekowe: młodych dorosłych (ludzi pełnoletnich do ukończenia 35 roku życia), dorosłych (ludzi w wieku od 35 do ukończenia 55 roku życia) oraz ludzi starszych (65+). Finalny rozkład z podziałem na grupy wiekowe oraz płeć można zaobserwować na Rysunku 3.



Rysunek 3: Struktura płci i grup wiekowych uczestników eksperymentu.

Następnie dla każdej osoby, używając języka R oraz pakietu *Quickpsy*, stworzyliśmy funkcje psychometryczne oparte o metody opisane w sekcji 2.2 i przeprowadziliśmy analizę punktu równości subiektywnej (ang. PSE, *Point of Subjective Equality*). Jest to taki punkt, w którym uczestnik zaczyna zauważać różnicę w natężeniu bodźca (tutaj: zmianie jakości). Prawdopodobieństwo naciśnięcia przycisku w punkcie równości subiektywnej wynosi 50%, jest to zatem jeden z progów psychofizycznych.

Analiza dla średnich PSE spośród trzech grup została wykonana z użyciem ANOVA. Wcześniej sprawdziliśmy jednorodność wariancji za pomocą testu Bartlett'a, otrzymując $p = 0,1642$. Jako że $p > 0,05$, nie możemy odrzucić hipotezy, że wariancje w różnych grupach są równe. Przyśladaliśmy zatem do analizy poszczególnych grup, której efekty można obserwować na Rysunku 4.



Rysunek 4: Charakterystyka poszczególnych grup wiekowych: młodzi: [18 – 35), dorośli: < 35 – 55) oraz osoby starsze: 65+. Czerwony punkt reprezentuje wartość średnią, natomiast niebieskie punkty odpowiadają wartościom indywidualnym.

W grupie osób młodszych wartość PSE wynosi 24,2529, natomiast średnia szerokość przedziału ufności osiąga 6,5688. Zaobserwowaliśmy, że wariancja PSE w tej grupie jest najwyższa, przy stosunkowo równomiernym rozproszeniu wyników. W grupie tej zidentyfikowaliśmy również uczestnika o najwyższej wrażliwości (identyfikator 15), dla którego PSE wynosi 6,9039, a szerokość przedziału ufności 1,7274. Uczestnik ten charakteryzuje się wysoką spójnością odpowiedzi oraz zdolnością do wykrywania subtelnych zmian w degradacji jakości.

W grupie osób dorosłych średnia wartość PSE wyno-

si 35,3778, a średnia szerokość przedziału ufności 50,1072, co oznacza, że grupa ta charakteryzuje się najwyższą średnią w porównaniu z pozostałymi. W tej grupie wyróżnia się uczestnik o identyfikatorze 3, którego PSE wynosi 50,5685, a szerokość przedziału ufności osiąga 144,7674. Może to sugerować, że odpowiedzi tego uczestnika są niespójne, a jego reakcje na pogarszającą się jakość — chaotyczne.

W grupie osób starszych średnia wartość PSE wynosi 33,5172, a średnia szerokość przedziału ufności 8,1233. Rozkład wartości cechuje się prawoskośnością: większość uczestników w tej grupie wiekowej osiągnęła niższe wartości PSE niż średnia, a jedynie dwie osoby uzyskały wyższe wyniki. Ciekawym przypadkiem odstającym jest uczestnik o identyfikatorze 35, którego wyniki były zbliżone do średnich wartości uzyskanych przez osoby młodsze.

Wyniki testu ANOVA nie wykazały istotnych statystycznie różnic pomiędzy średnimi wartościami PSE w poszczególnych grupach wiekowych ($F(2; 28) = 2,707; p = 0,0842$) przy założeniu $\alpha = 0,05$.

4. DYSKUSJA

W niniejszym artykule zaprezentowaliśmy nową procedurę eksperymentu opartego na reakcji na degradację jakości wideo oraz wykorzystanie zaadaptowanej metody dopasowania funkcji psychometrycznych. Na ich podstawie możemy porównać punkty, w których uczestnicy eksperymentu zaczęli dostrzegać degradację jakości: posługując się pierwotną metryką VMAF obserwujemy, że średnio grupa młodych ludzi zaczyna zauważać degradację jakości już przy wartości VMAF 75. Ciekawym wnioskiem jest fakt, że kolejną grupą są osoby starsze z wynikiem VMAF 66, a na końcu dorośli z wynikiem VMAF 50. Jest to zaskakujące, gdyż ze względu na podeszły wiek i związane z tym problemy ze wzrokiem oczekivalibyśmy innych wyników.

Należy jednak zwrócić uwagę na fakt, że grupa dorosłych jest zdecydowanie mniej liczna od pozostałych. Związane jest to z faktem, że grupa ta jest aktywna zawodowo i bardzo trudno zachęcić ją do wzięcia udziału w tego typu eksperymencie (ang. *hard-to-reach population* [8]). Dodatkowa obecność chaotycznego i niespójnego uczestnika o identyfikatorze 3, ogranicza możliwość generalizowania wyników na populację.

Niewielka liczebność grupy dorosłych może być także powodem braku statystycznie istotnych różnic w teście ANOVA ($p = 0,0842$), który wykazuje jednak obiecujący wynik dla większych wartości parametru α .

5. PODZIĘKOWANIA

Referat został sfinansowany przez Ministerstwo Nauki i Szkolnictwa Wyższego w ramach subwencji dla Wydziału Informatyki, Elektroniki i Telekomunikacji AGH.

Badania prowadzące do tych wyników zostały sfinansowane z Norweskiego Mechanizmu Finansowego 2014-2021 w projekcie 2019/34/H/ST6/00599.

LITERATURA

- [1] de'Sperati C. i Bovy G. B. 2017. „Low perceptual sensitivity to altered video speed in viewing a soccer match”. *Scientific reports* 7, 1 (2017), 15379.
- [2] Mittal A., Moorthy A. K., Bovik A. C. 2011. „Blind/Referenceless Image Spatial Quality Evaluator,” 2011 Conference Record of the Forty Fifth Asilomar Conference on Signals, Systems and Computers (ASILOMAR), Pacific Grove, CA, USA, 2011, pp. 723-727, doi: 10.1109/ACSSC.2011.6190099.
- [3] ITU-T. 2019. P.917 „Subjective test methodology for assessing impact of initial loading delay on quality of experience”. P.917.
- [4] Klein S. A. 2001. „Measuring, estimating, and understanding the psychometric function: A commentary”. *Perception Psychophysics* 63 pp. 1421–1455. issn: 0031-5117. doi: 10.3758/BF03194552.
- [5] Li Z et al. 2016. „Toward A Practical Perceptual Video Quality Metric”. url: <https://netflixtechblog.com/toward-a-practical-perceptual-video-quality-metric-653f208b9652>.
- [6] Linares D. i López-Moliner J. 2016. „quickpsy: An R Package to Fit Psychometric Functions for Multiple Groups”. *The R Journal* 8 (2016), 122. Issue 1. doi:10.32614/RJ-2016-008
- [7] Saad M. A., Bovik A. C. , i Charrier C. , „Blind prediction of natural video quality,” *IEEE Trans. Image Process.*, vol. 23, no. 3, pp. 1352–1365, Mar. 2014.
- [8] Shaghghi A, Bhopal RS, Sheikh A. „Approaches to Recruiting 'Hard-To-Reach' Populations into Re-search: A Review of the Literature”. *Health Promot Perspect.* 2011 Dec 20;1(2):86-94. doi: 10.5681/hpp.2011.009. PMID: 24688904; PMCID: PMC3963617.
- [9] Venkatanath N, Praneeth D, Maruthi Chandrasekhar Bh, S. S. Channappayya and S. S. Medasani. 2015. „Blind image quality evaluation using perception based features,” *Twenty First National Conference on Communications (NCC)*, Mumbai, India, 2015, pp. 1-6, doi: 10.1109/NCC.2015.7084843.